

14

Revisit Random Variables

再谈随机变量

从几何视角探讨随机变量的函数



自然的一般规律在大多数情况下不是直接的感知对象。

The general laws of Nature are not, for the most part, immediate objects of perception.

—— 乔治·布尔 (George Boole) | 英格兰数学家和哲学家 | 1815 ~ 1864



- ⊗ XXX
- ⊗ XXX
- ⊗ XXX



14.1 随机变量的函数：以鸢尾花为例

我们在本书第 3、4 章聊过色子点数的“花式玩法”，比如点数之和、点数平均值、点数之差、点数平方、点数之商等等。这些“花式玩法”都可以叫做随机变量的函数。

随机变量的函数可以分为两类：线性变换 (linear transformation)、非线性变换 (nonlinear transformation)。

比如，点数之和 ($X_1 + X_2$)、点数之差 ($X_1 - X_2$)、点数平均值 $((X_1 + X_2)/2)$ 等都是线性变换。此外，去均值 ($X_1 - E(X_1)$)、标准化 $((X_1 - E(X_1))/\text{std}(X_1))$ 也都是常见的随机变量的线性变换。线性变换是本章的核心内容。

线性变换之外的随机变量变换都统称为非线性变换，比如平方 (X_1^2)、平方求和 ($\sum_j X_j^2$)、乘积 ($X_1 X_2$)、比例 (X_1/X_2)、倒数 ($1/X_1$)、对数变换 ($\ln X_1$) 等等。此外，本书第 9 章介绍的经验分布哈函数 ECDF 也是常用的非线性变换，ECDF 将原始数据转化成 (0, 1) 区间之内的分位值。

注意，经过转换后的随机变量，其分布、期望值、方差等都会发生变化。

从数据角度来看，以上变换又叫数据转化 (data transformation)，这是《数据有道》一册的话题。

以鸢尾花数据为例

它的前 4 列特征分别为花萼长度 (X_1)、花萼宽度 (X_2)、花瓣长度 (X_3)、花瓣宽度 (X_4)。假如在一个有关鸢尾花的研究中，为了进一步挖掘鸢尾花数据中可能存在的量化关系，我们需要分析如下几个指标：

- ▶ 花萼长度去均值，即 $X_1 - E(X_1)$;
- ▶ 花萼宽度去均值，即 $X_2 - E(X_2)$;
- ▶ 花萼长度、宽度之和，即 $X_1 + X_2$;
- ▶ 花萼长度、宽度之差，即 $X_1 - X_2$;
- ▶ 花萼长度、宽度乘积，即 $X_1 X_2$;
- ▶ 花萼长度、宽度比例，即 X_1/X_2 。

图 1 所示为经过上述转换后得到的鸢尾花新特征之间的成对特征散点图。这些新特征之间的成对关系中，有些展现出明显的线性关系，有些特征更方便判别鸢尾花分类，有些特征展现出更好的“正态性”，有些则更容易发现“离群值”。

请大家利用成对特征图分析更多鸢尾花特征的随机变量函数。此外，请大家依照同样的方法分析花瓣长度、宽度数据，并且交叉分析花萼、花瓣量化关系。

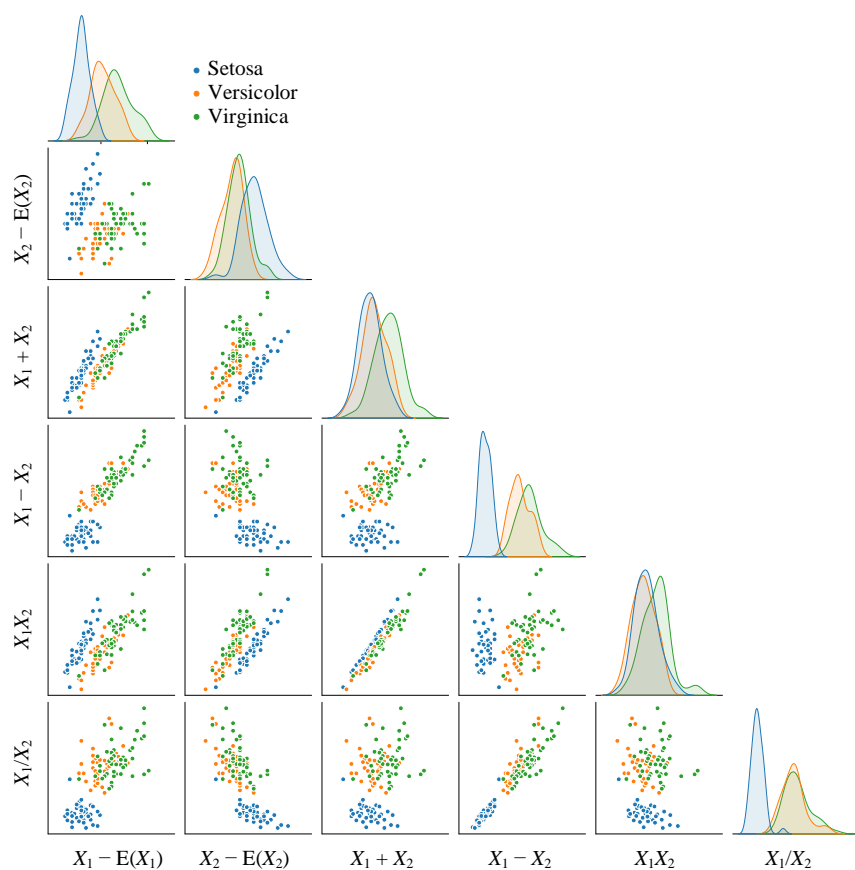


图 1. 鸢尾花花萼长度、宽度特征完成转换后的成对特征散点图

14.2 线性变换：投影视角

《矩阵力量》第 25 章介绍过随机变量的线性变换，我们其中核心理论部分“抄”过来。本章后文会用鸢尾花数据展开讲解。

一元随机变量

如果 X 为一个随机变量，对 X 进行函数变换，可以得到其他的随机变量 Y ：

$$Y = h(X) \quad (1)$$

特别地，如果 $h()$ 为线性函数，则 X 到 Y 进行的就线性变换，比如：

$$Y = h(X) = aX + b \quad (2)$$

其中， a 和 b 为常数。这相当于几何中的缩放、平移两步操作。在线性代数中，上式相当于仿射变换 (affine transformation)。

本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微课视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

(2) 中, Y 的期望和 X 的期望之间关系:

$$E(Y) = aE(X) + b \quad (3)$$

(2) 中, Y 和 X 方差之间关系:

$$\text{var}(Y) = \text{var}(aX + b) = a^2 \text{var}(X) \quad (4)$$

二元随机变量

如果 Y 和二元随机变量 (X_1, X_2) 存在如下关系:

$$Y = aX_1 + bX_2 \quad (5)$$

(5) 可以写成:

$$Y = \begin{bmatrix} a & b \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \quad (6)$$

Y 和二元随机变量 (X_1, X_2) 期望值之间存在如下关系:

$$E(Y) = E(aX_1 + bX_2) = aE(X_1) + bE(X_2) \quad (7)$$

(7) 可以写成如下矩阵运算形式:

$$E(Y) = \begin{bmatrix} a & b \end{bmatrix} \begin{bmatrix} E(X_1) \\ E(X_2) \end{bmatrix} \quad (8)$$

Y 和二元随机变量 (X_1, X_2) 方差、协方差存在如下关系:

$$\text{var}(Y) = \text{var}(aX_1 + bX_2) = a^2 \text{var}(X_1) + b^2 \text{var}(X_2) + 2ab \text{cov}(X_1, X_2) \quad (9)$$

(9) 可以写成:

$$\text{var}(Y) = \begin{bmatrix} a & b \end{bmatrix} \underbrace{\begin{bmatrix} \text{var}(X_1) & \text{cov}(X_1, X_2) \\ \text{cov}(X_1, X_2) & \text{var}(X_2) \end{bmatrix}}_{\Sigma} \begin{bmatrix} a \\ b \end{bmatrix} \quad (10)$$

相信大家已经在上式中看到了如下协方差矩阵:

$$\Sigma = \begin{bmatrix} \text{var}(X_1) & \text{cov}(X_1, X_2) \\ \text{cov}(X_1, X_2) & \text{var}(X_2) \end{bmatrix} \quad (11)$$

也就是说, (10) 可以写成:

$$\text{var}(Y) = \begin{bmatrix} a & b \end{bmatrix} \Sigma \begin{bmatrix} a \\ b \end{bmatrix} \quad (12)$$

D 维随机变量：朝单一方向投影

如果 $\chi = [X_1, X_2, \dots, X_D]^T$ 服从 $N(\mu_\chi, \Sigma_\chi)$, χ 在向量 \mathbf{v} 方向上投影得到 Y :

$$Y = \mathbf{v}^T \chi = \mathbf{v}^T \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_D \end{bmatrix} \quad (13)$$

Y 的期望 $E(Y)$ 为:

$$E(Y) = \mathbf{v}^T \mu_\chi = \mathbf{v}^T \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_D) \end{bmatrix} \quad (14)$$

Y 的方差 $E(Y)$ 为:

$$\text{var}(Y) = \mathbf{v}^T \Sigma_\chi \mathbf{v} \quad (15)$$

D 维随机变量：朝正交系投影

$\chi = [X_1, X_2, \dots, X_D]^T$ 服从 $N(\mu_\chi, \Sigma_\chi)$, χ 在正交系 \mathbf{V} 投影得到 $\gamma = [Y_1, Y_2, \dots, Y_D]^T$:

$$\gamma = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_D \end{bmatrix} = \mathbf{V}^T \chi = \begin{bmatrix} \mathbf{v}_1^T \\ \mathbf{v}_2^T \\ \vdots \\ \mathbf{v}_D^T \end{bmatrix} \chi = \begin{bmatrix} \mathbf{v}_1^T \chi \\ \mathbf{v}_2^T \chi \\ \vdots \\ \mathbf{v}_D^T \chi \end{bmatrix} \quad (16)$$

γ 的期望 (质心) $E(\gamma)$ 为:

$$E(\gamma) = \mathbf{V}^T \mu_\chi = \begin{bmatrix} \mathbf{v}_1^T \\ \mathbf{v}_2^T \\ \vdots \\ \mathbf{v}_D^T \end{bmatrix} \mu_\chi = \begin{bmatrix} \mathbf{v}_1^T \mu_\chi \\ \mathbf{v}_2^T \mu_\chi \\ \vdots \\ \mathbf{v}_D^T \mu_\chi \end{bmatrix} \quad (17)$$

γ 的协方差矩阵 $\text{var}(\gamma)$ 为:

$$\text{var}(\gamma) = \mathbf{V}^T \Sigma_\chi \mathbf{V} = \begin{bmatrix} \mathbf{v}_1^T \\ \mathbf{v}_2^T \\ \vdots \\ \mathbf{v}_D^T \end{bmatrix} \Sigma_\chi \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_D \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1^T \Sigma_\chi \mathbf{v}_1 & \mathbf{v}_1^T \Sigma_\chi \mathbf{v}_2 & \cdots & \mathbf{v}_1^T \Sigma_\chi \mathbf{v}_D \\ \mathbf{v}_2^T \Sigma_\chi \mathbf{v}_1 & \mathbf{v}_2^T \Sigma_\chi \mathbf{v}_2 & \cdots & \mathbf{v}_2^T \Sigma_\chi \mathbf{v}_D \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{v}_D^T \Sigma_\chi \mathbf{v}_1 & \mathbf{v}_D^T \Sigma_\chi \mathbf{v}_2 & \cdots & \mathbf{v}_D^T \Sigma_\chi \mathbf{v}_D \end{bmatrix} \quad (18)$$

上式还告诉我们， $\mathbf{v}_i^T \boldsymbol{\chi}$ 和 $\mathbf{v}_j^T \boldsymbol{\chi}$ 的协方差为：

$$\text{cov}(\mathbf{v}_i^T \boldsymbol{\chi}, \mathbf{v}_j^T \boldsymbol{\chi}) = \mathbf{v}_i^T \boldsymbol{\Sigma}_{\boldsymbol{\chi}} \mathbf{v}_j \quad (19)$$

14.3 单方向投影：鸢尾花两特征为例

本节以鸢尾花数据花萼长度、花萼宽度两特征为例讲解线性变换。我们首先看两个最简单的例子，将数据分别投影到横轴、纵轴。然后再看更一般的情况。

投影到 \mathbf{x} 轴

鸢尾花数据矩阵为 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2]$ ，对应随机变量为 $\boldsymbol{\chi} = [X_1, X_2]^T$ 。

如图 2 所示，将 \mathbf{X} 投影到横轴，即：

$$\mathbf{y} = \mathbf{X}\mathbf{v} = \mathbf{X} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \mathbf{x}_1 \quad (20)$$

从随机变量角度来看上述运算，即：

$$Y = \mathbf{v}^T \boldsymbol{\chi} = \begin{bmatrix} 1 & 0 \end{bmatrix}^T \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = X_1 \quad (21)$$




图 2. 逆时针 0 度， \mathbf{X} 向 \mathbf{v} 投影

\mathbf{X} 的质心为：

$$E(\mathbf{X}) = \begin{bmatrix} 5.8433 & 3.0573 \end{bmatrix} \quad (22)$$

由此计算得到图 2 中 y 的质心为：

$$E(y) = E(\mathbf{X})\mathbf{v} = \begin{bmatrix} 5.8433 & 3.0573 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = 5.8433 \quad (23)$$

\mathbf{X} 的协方差矩阵为：

$$\Sigma_{\mathbf{X}} = \begin{bmatrix} 0.6856 & -0.0424 \\ -0.0424 & 0.1899 \end{bmatrix} \quad (24)$$

由此计算得到图 2 中 y 的方差为：

$$\text{var}(y) = \mathbf{v}^T \text{var}(\mathbf{X})\mathbf{v} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}^T \begin{bmatrix} 0.6856 & -0.0424 \\ -0.0424 & 0.1899 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = 0.6856 \quad (25)$$

注意，图 2 中椭圆代表马氏距离。三个黑色旋转椭圆分别代表马氏距离为 1、2、3。将图 2 中三个椭圆也投影到横轴上，大家会发现得到的三条线段分别代表 $\mu_1 \pm \sigma_1$ 、 $\mu_1 \pm 2\sigma_1$ 、 $\mu_1 \pm 3\sigma_1$ 。这绝不是几何上的巧合，本章后续会展开讲解。

投影到 y 轴

如图 3 所示，将 \mathbf{X} 投影到纵轴，即：

$$y = \mathbf{X}\mathbf{v} = \mathbf{X} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = x_2 \quad (26)$$

从随机变量角度来看上述运算，即：


$$Y = \mathbf{v}^T \mathbf{X} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}^T \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = X_2 \quad (27)$$

计算图 3 中 y 的质心为：

$$E(y) = E(\mathbf{X})\mathbf{v} = \begin{bmatrix} 5.8433 & 3.0573 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = 3.0573 \quad (28)$$


计算得到图 3 中 y 的方差为：

$$\text{var}(y) = \mathbf{v}^T \text{var}(\mathbf{X})\mathbf{v} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}^T \begin{bmatrix} 0.6856 & -0.0424 \\ -0.0424 & 0.1899 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = 0.1899 \quad (29)$$

图 3. 逆时针 90 度, X 向 v 投影

其他情况

图 4 ~ 图 7 所示为其他四个投影场景。

图 4. 逆时针 5 度, X 向 v 投影




图 5. 逆时针 45 度, X 向 v 投影




图 6. 逆时针 75 度, X 向 v 投影





图 7. 逆时针 -5 度, X 向 v 投影



代码 Bk5_Ch14_01.py 绘制图 2 ~ 图 7。

14.4 正交系投影：鸢尾花两特征为例

正交系

给定正交系 V :

$$V = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \quad (30)$$

如图 8 所示，数据 X 可以投影到正交系 V 中得到数据 Y :

$$Y = XV \quad (31)$$

展开上式得到:

$$\begin{bmatrix} y_1 & y_2 \end{bmatrix} = X \begin{bmatrix} v_1 & v_2 \end{bmatrix} = \begin{bmatrix} Xv_1 & Xv_2 \end{bmatrix} \quad (32)$$

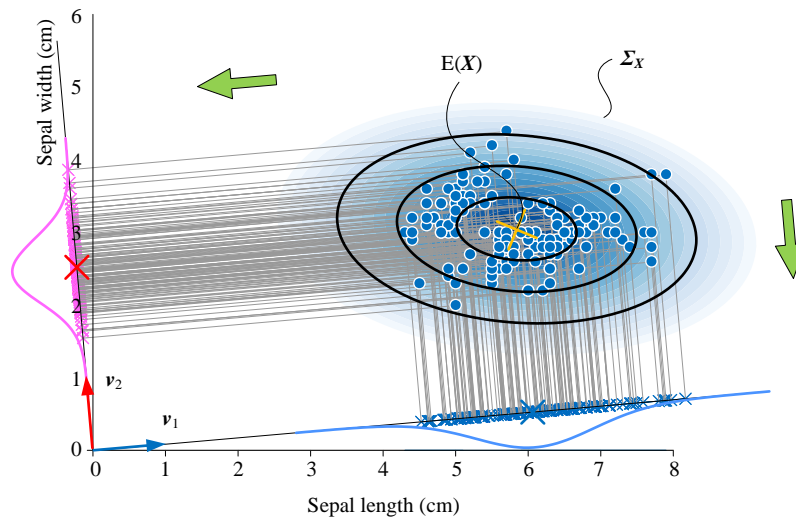


图 8. X 向正交系 V 投影

随机变量为 $\chi = [X_1, X_2]^T$ 投影到 V 得到 $\gamma = [Y_1, Y_2]^T$:

$$\boldsymbol{y} = \boldsymbol{V}^T \boldsymbol{x} \quad (33)$$

展开上式得到：

$$\begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \boldsymbol{V}^T \boldsymbol{x} = \begin{bmatrix} \boldsymbol{v}_1^T \\ \boldsymbol{v}_2^T \end{bmatrix} \boldsymbol{x} = \begin{bmatrix} \boldsymbol{v}_1^T \boldsymbol{x} \\ \boldsymbol{v}_2^T \boldsymbol{x} \end{bmatrix} \quad (34)$$

向第一方向投影

先考虑 \boldsymbol{x} 向 \boldsymbol{v}_1 投影：

$$\boldsymbol{v}_1 = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \quad (35)$$

将数据 \boldsymbol{x} 投影到 \boldsymbol{v}_1 得到：

$$\boldsymbol{y}_1 = \boldsymbol{x} \boldsymbol{v}_1 \quad (36)$$

类似地，将 $\boldsymbol{x} = [X_1, X_2]^T$ 投影到 \boldsymbol{v}_1 得到 Y_1 ：

$$Y_1 = [X_1 \quad X_2] \boldsymbol{v}_1 = [X_1 \quad X_2] \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} = \cos \theta X_1 + \sin \theta X_2 \quad (37)$$

Y_1 的质心为：

$$\begin{aligned} E(Y_1) &= E(\boldsymbol{x}) \boldsymbol{v}_1 = \begin{bmatrix} 5.8433 & 3.0573 \end{bmatrix} \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \\ &\approx 3.0573 \times \sin(\theta) + 5.8433 \times \cos(\theta) \end{aligned} \quad (38)$$

Y_1 的方差为：

$$\begin{aligned} \text{var}(Y_1) &= \boldsymbol{v}_1^T \boldsymbol{\Sigma}_x \boldsymbol{v}_1 = \begin{bmatrix} \cos \theta & \sin \theta \end{bmatrix} \begin{bmatrix} 0.6856 & -0.0424 \\ -0.0424 & 0.1899 \end{bmatrix} \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \\ &\approx -0.0424 \times \sin(2\theta) + 0.2478 \times \cos(2\theta) + 0.4378 \end{aligned} \quad (39)$$

向第二方向投影

同理，给定 \boldsymbol{v}_2 ：

$$\boldsymbol{v}_2 = \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix} \quad (40)$$

将数据 \boldsymbol{x} 投影到 \boldsymbol{v}_2 得到：

$$\boldsymbol{y}_2 = \boldsymbol{x} \boldsymbol{v}_2 \quad (41)$$

将 $\boldsymbol{x} = [X_1, X_2]^T$ 投影到 \boldsymbol{v}_2 得到 Y_2 :

$$Y_2 = [X_1 \ X_2] \boldsymbol{v}_2 = [X_1 \ X_2] \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix} = -\sin \theta X_1 + \cos \theta X_2 \quad (42)$$

Y_2 的质心为:

$$\begin{aligned} \mu_{Y_2} &= E(\boldsymbol{X}) \boldsymbol{v}_2 = [5.8433 \ 3.0573] \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix} \\ &\approx -5.8433 \times \sin(\theta) + 3.0573 \times \cos(\theta) \end{aligned} \quad (43)$$

Y_2 的方差为:

$$\begin{aligned} \text{var}(Y_2) &= \boldsymbol{v}_2^T \boldsymbol{\Sigma}_X \boldsymbol{v}_2 = \begin{bmatrix} -\sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} 0.6856 & -0.0424 \\ -0.0424 & 0.1899 \end{bmatrix} \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix} \\ &\approx 0.0424 \times \sin(2\theta) - 0.2478 \times \cos(2\theta) + 0.4378 \end{aligned} \quad (44)$$

协方差

Y_1 和 Y_2 的协方差为:

$$\begin{aligned} \text{cov}(Y_1, Y_2) &= \boldsymbol{v}_1^T \boldsymbol{\Sigma}_X \boldsymbol{v}_2 = \begin{bmatrix} \cos \theta & \sin \theta \end{bmatrix} \begin{bmatrix} 0.6856 & -0.0424 \\ -0.0424 & 0.1899 \end{bmatrix} \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix} \\ &\approx 0.2478 \times \sin(2\theta) + 0.0424 \times \cos(2\theta) \end{aligned} \quad (45)$$

利用如下三角函数关系:

$$\begin{aligned} f(\theta) &= a \sin(\theta) + b \cos(\theta) \\ &= \sqrt{a^2 + b^2} \left(\frac{a}{\sqrt{a^2 + b^2}} \sin(\theta) + \frac{b}{\sqrt{a^2 + b^2}} \cos(\theta) \right) \\ &= \sqrt{a^2 + b^2} (\sin(\theta) \cos(\phi) + \cos(\theta) \sin(\phi)) \\ &= A \sin(\theta + \phi) \end{aligned} \quad (46)$$


其中,

$$\begin{aligned} \phi &= \arctan\left(\frac{b}{a}\right) \\ A &= \sqrt{a^2 + b^2} \end{aligned} \quad (47)$$

我们可以进一步整理 (38)、(39)、(43)、(44)、(45)，这部分推导交给大家完成。

如图 9 所示，期望值、方差、协方差随 θ 变化。请大家特别注意 Y_1 和 Y_2 的方差之和为定值，即：

$$\begin{aligned}\text{var}(Y_1) + \text{var}(Y_2) &\approx -0.0424 \times \sin(2\theta) + 0.2478 \times \cos(2\theta) + 0.4378 + \\ &\quad 0.0424 \times \sin(2\theta) - 0.2478 \times \cos(2\theta) + 0.4378 \\ &\approx 0.8756\end{aligned}\quad (48)$$

图 9. y_1 和 y_2 各种量化关系随 θ 变化

协方差矩阵

$\gamma = [Y_1, Y_2]^T$ 的协方差矩阵 Σ_γ 为：

$$\text{var}(\gamma) = \Sigma_\gamma = V^T \Sigma_X V \quad (49)$$

图 10 所示为当 θ 取不同值时，协方差矩阵 Σ_γ 的三种不同可视化方案的变化情况。

特别地，如图 10 (b) 所示，当 θ 约为 -4.85 度时，协方差矩阵 Σ_γ 为对角方阵。这意味着 Y_1 和 Y_2 的相关性系数为 0。

在图 9 中，我们可以发现，当 θ 约为 -4.85 度时， $\text{var}(Y_1)$ 取得最大值， $\text{var}(Y_2)$ 取得最小值。如图 11 所示为数据矩阵在这个正交坐标系中投影的结果。这一点对于本章后续要讲解的主成分分析非常重要。





图 10. 协方差矩阵的可视化

图 11. X 向正交系 V 投影, -4.8575°

14.5 以椭圆投影为视角看线性变换

本节将从椭圆投影视角理解随机变量的线性转换。

“正” 矩形

如图 12 所示，三个“正”矩形的四条边分别和马氏距离为 1、2、3 的椭圆相切。其中，和马氏距离为 1 的矩形相切的矩形的长、宽分别为 $2\sigma_1$ 、 $2\sigma_2$ 。

上一章提到过，图 12 中这个大矩形的面积为 $4\sigma_1\sigma_2$ ，其对角线长度为矩形对角线长度为 $2\sqrt{\sigma_1^2 + \sigma_2^2}$ 。

上一章特别强调图 12 中阴影区域对应的 1/4 矩形。这个 1/4 矩形的面积为 $\sigma_1\sigma_2$ ，1/4 矩形对角线长度为 $\sqrt{\sigma_1^2 + \sigma_2^2}$ ，这个值是其协方差迹的平方根 $\sqrt{\sigma_1^2 + \sigma_2^2} = \sqrt{\text{tr}(\Sigma_{2 \times 2})}$ 。

根据本章有关随机变量线性变换内容，如图 12 所示，这三个矩形“长边”所在位置分别对应 $\mu_1 \pm \sigma_1$ 、 $\mu_1 \pm 2\sigma_1$ 、 $\mu_1 \pm 3\sigma_1$ 。“宽边”所在位置分别对应 $\mu_2 \pm \sigma_2$ 、 $\mu_2 \pm 2\sigma_2$ 、 $\mu_2 \pm 3\sigma_2$ 。这并不是巧合，本节后续将用数学工具加以证明。




图 12. 和马氏距离椭圆相切的“正”矩形

“主轴”矩形

如图 13 所示，和马氏距离为 1 的椭圆相切的矩形有无数个。观察这些矩形，大家能够发现它们的顶点位于正圆之上。这意味着这些矩形的对角线长度相同，都是 $2\sqrt{\sigma_1^2 + \sigma_2^2}$ 。想要证明这个观察，需要用到矩阵迹的性质，证明留给大家自行完成。

除了图 12 中的“正”矩形之外，还有一个“旋转”矩形特别值得我们关注。这就是图 14 所示的“主轴”矩形。之所以叫“主轴”矩形，是因为这个矩形的四条边平行于椭圆的两条主轴。

而特征值分解协方差矩阵就是获得椭圆主轴方向、长轴长度、短轴长度的数学工具。请大家根据上一章内容自行分析图 14 中和马氏距离为 1 椭圆相切的“主轴”矩形的几何特征。

请大家格外注意，特征值和投影获得的两个分布的方差、标准差关系。




图 13. 和马氏距离椭圆相切的一组“旋转”矩形




图 14. 和马氏距离椭圆相切的“主轴”矩形

椭圆切线

大家可能好奇如何绘制图 13 这组旋转矩形。如图 15 所示，首先，计算椭圆圆心 μ 和椭圆上任意一点 p 切线的距离 h 。 $2h$ 就是矩形一条边长度。而切线的梯度向量 n 可以用来定位矩形的旋转角度。然后，根据矩形的对角线长度为 $2\sqrt{\sigma_1^2 + \sigma_2^2}$ ，我们便得到矩形另外一条边的长度。

本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微课视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

问题来了，如何计算距离 h 和梯度向量 \mathbf{n} ？




图 15. 计算马氏椭圆上任意一点切线原理

我们在《矩阵力量》第 20 章介绍过如何求解椭圆切线。图 15 中椭圆的解析式为：

$$(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) - 1 = 0 \quad (50)$$

\mathbf{p} 在椭圆上，如下等式成立：

$$(\mathbf{p} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{p} - \boldsymbol{\mu}) - 1 = 0 \quad (51)$$

定义如下函数 $f(\mathbf{x})$ ：

$$f(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) - 1 = 0 \quad (52)$$

$f(\mathbf{x})$ 对 \mathbf{x} 求偏导便得到梯度向量 \mathbf{n} ：

$$\mathbf{n} = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = 2\boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \quad (53)$$

上式用到了《矩阵力量》第 17 章的多元微分。也就是说，图 13 中椭圆上 \mathbf{p} 点处切线的法向量为：

$$\mathbf{n} = 2\boldsymbol{\Sigma}^{-1} (\mathbf{p} - \boldsymbol{\mu}) \quad (54)$$

切点 \mathbf{p} 和椭圆圆心 $\boldsymbol{\mu}$ 的距离向量 $\mathbf{p} - \boldsymbol{\mu}$ ，对应图 13 中的绿色箭头。而距离 h 就是向量 $\mathbf{p} - \boldsymbol{\mu}$ 在梯度向量 \mathbf{n} 上的标量投影：

$$h = \frac{\mathbf{n}^T (\mathbf{p} - \boldsymbol{\mu})}{\|\mathbf{n}\|} \quad (55)$$

有了以上推导，请大家自行编写代码绘制图 14。进一步推导，大家可以得到：

$$h^2 = \frac{\mathbf{n}^T \boldsymbol{\Sigma} \mathbf{n}}{\|\mathbf{n}\|^2} = \left(\frac{\mathbf{n}}{\|\mathbf{n}\|} \right)^T \boldsymbol{\Sigma} \left(\frac{\mathbf{n}}{\|\mathbf{n}\|} \right) \quad (56)$$

上式解释了为什么矩形边长 $1/2$ 为标准差。

14.6 主成分分析：换个视角看数据

丛书几次提到，从几何角度，协方差矩阵 Σ 可以用椭圆来表达。利用这个几何视角，我们重新审视《矩阵力量》第 25 章介绍的协方差矩阵 Σ 特征值分解进行主成分分析。

Σ 特征值分解进行主成分分析的具体步骤如图 16 所示。假设图 16 原始数据已经标准化，计算得到协方差矩阵 Σ ，找到 Σ 对应椭圆的半长轴所在方向 v_1 。 v_1 对应的便是第一主成分 (first principal component)。原始数据朝 v_1 投影得到的数据对应最大方差。

整个过程实际上用到了我们在丛书《矩阵力量》一本中介绍的平移、缩放、正交化、投影、旋转等线性变换操作。

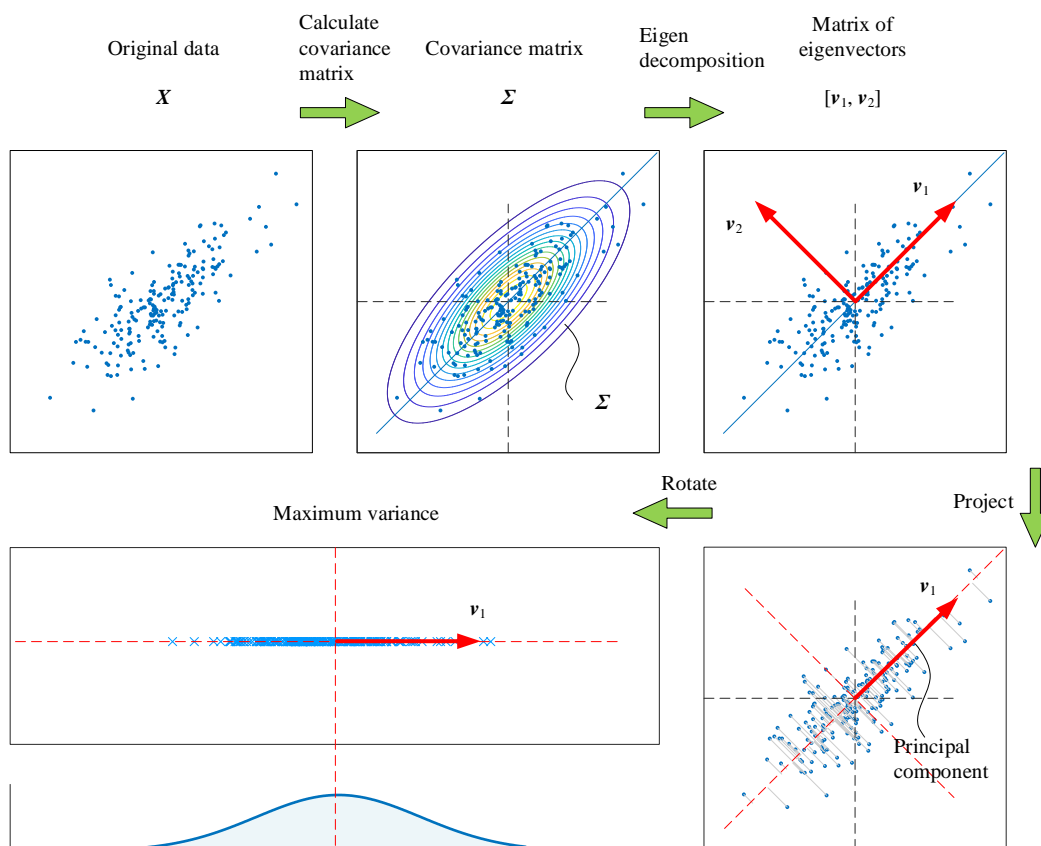


图 16. 几何视角下通过特征值分解协方差矩阵进行主成分分析

从线性变换角度来看，主成分分析无非就是，在不同的坐标系中看同一组数据。如图 17 所示，数据朝不同方向投影会得到不同的投影结果，对应不同的分布；朝椭圆长轴方向投影，得到的数据均方差最大；朝椭圆短轴方向投影得到的数据均方差最小。


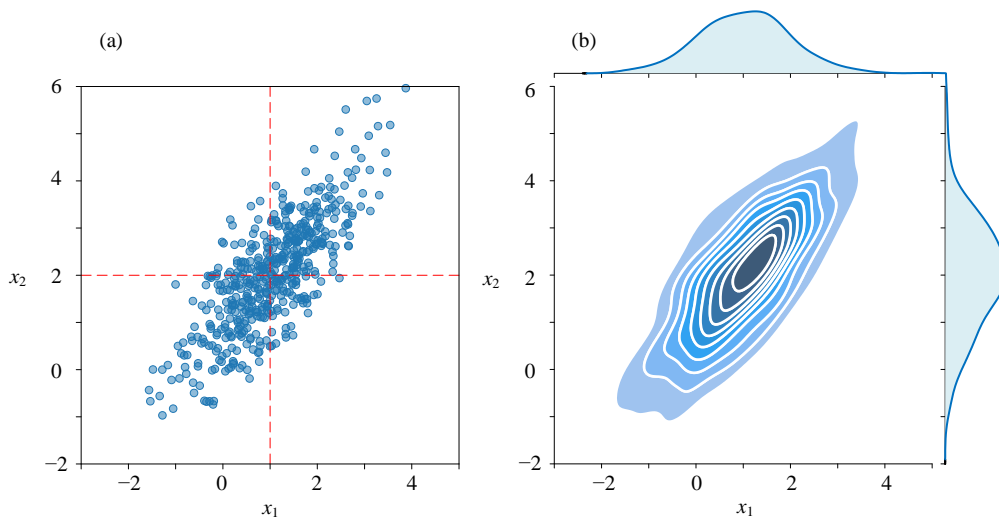


图 17. 两个角度看数据

举个例子

图 18 所示为原始二维数据 \mathbf{X} ，可以发现数据的质心位于 $[1, 2]^T$ 。分析数据 \mathbf{X} ，可以发现数据的两个特征上分布分散情况相似，也就是方差大小几乎相同。

图 18. 原始二维数据 \mathbf{X}

利用 `sklearn.decomposition.PCA()` 函数，我们可以通过 `pca.components_` 获得主成分向量。利用 `pca.transform(X)` 可以获得投影后的数据 \mathbf{Y} 。图 19 对比 \mathbf{Y} 两列数据分布。图 20 所示为数据 \mathbf{Y} 在 $[\mathbf{v}_1, \mathbf{v}_2]$ 中散点图。

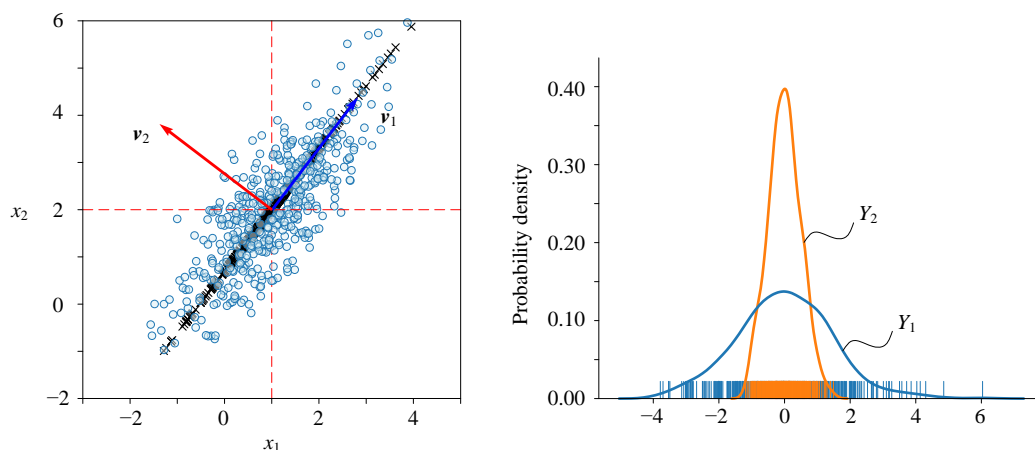
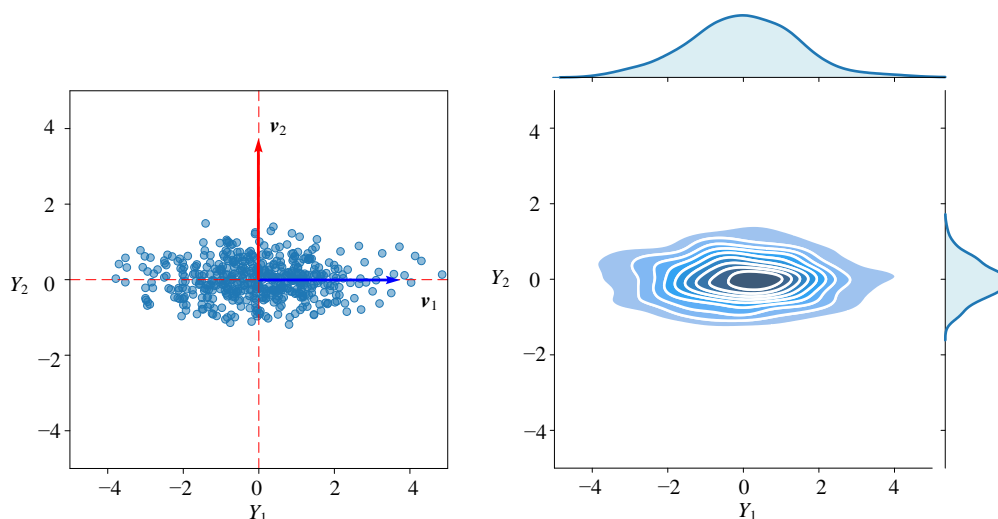


图 19. 主成分数据分布

图 20. 数据 Y 在 $[v_1, v_2]$ 中散点图

Bk5_Ch14_02.py 绘制图 18 ~ 图 20。

以鸢尾花数据为例

下面以鸢尾花数据作为原始数据，进一步从随机变量的线性变换角度理解主成分分析。

首先将鸢尾花花萼长度、花萼宽度数据中心化，即获得 $\mathbf{X}_c = \mathbf{X} - \mathbf{E}(\mathbf{X})$ 。图 21 所示为中心化数据的散点图。将数据投影到角度为逆时针 30 度的正交系 $\mathbf{V} = [v_1, v_2]$ 中。如前文所述，数据投影到

正交系中好比在 V 中观察数据，如图 22 所示。在 V 中，我们看到代表协方差矩阵的椭圆发生了明显旋转。在 v_1 和 v_2 方向上，我们可以求得投影数据的分布情况。

图 23 ~ 图 28 所示为其他 3 组投影角度。请大家格外注意图 27 和图 28，这就是前文说的最优化角度。这两幅图中的 v_1 和 v_2 分别为第一、第二主成分方向。

《矩阵力量》第 25 章介绍过，特征值分解协方差矩阵仅仅是主成分分析六条基本技术路径之一，本书第 25 章还会介绍其他路径，并做区分。

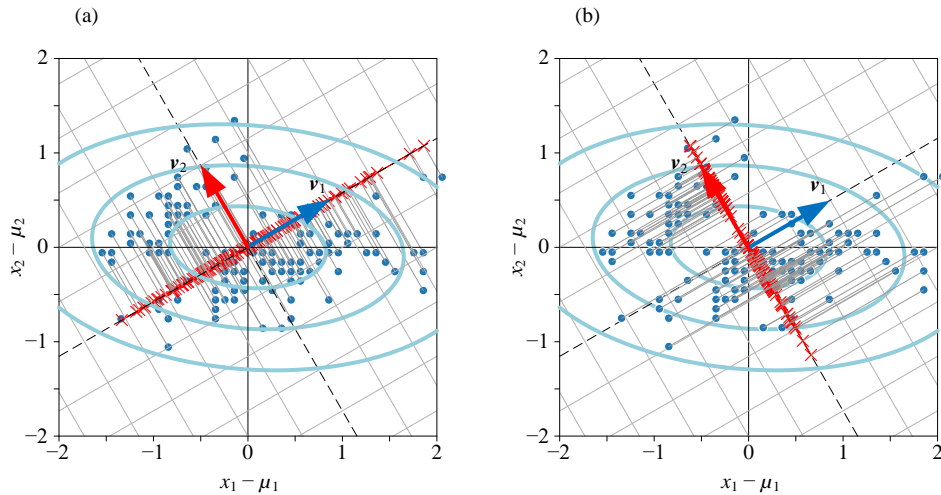


图 21. 正交系，逆时针 30 度

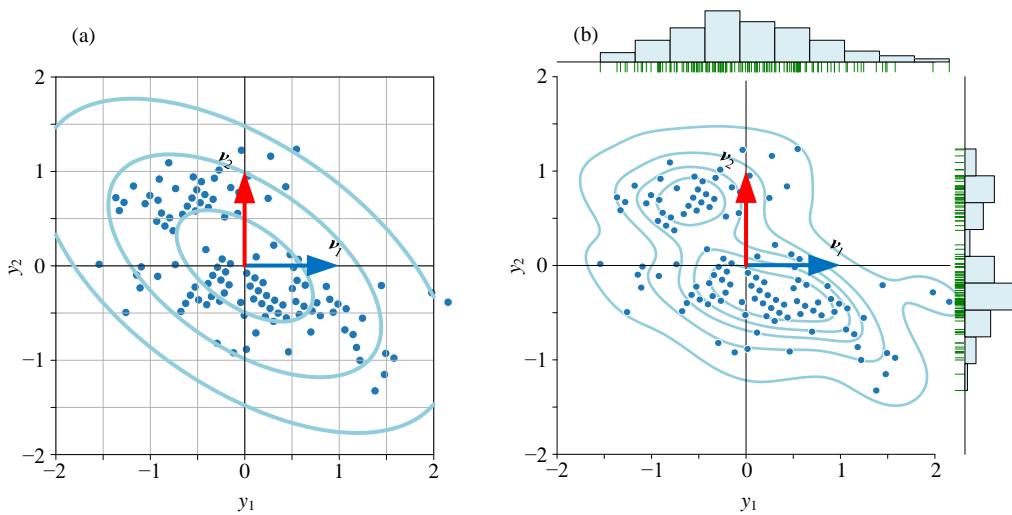


图 22. 数据顺时针旋转 30 度

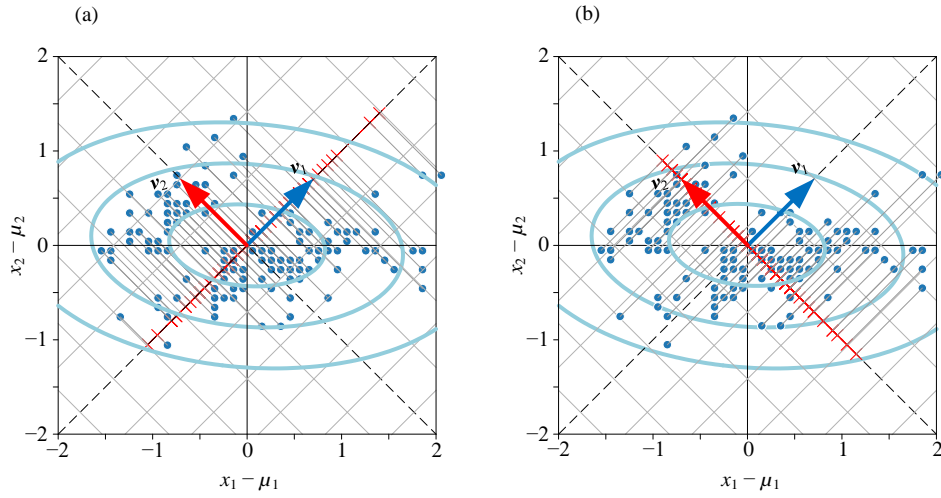


图 23. 正交系，逆时针 45 度

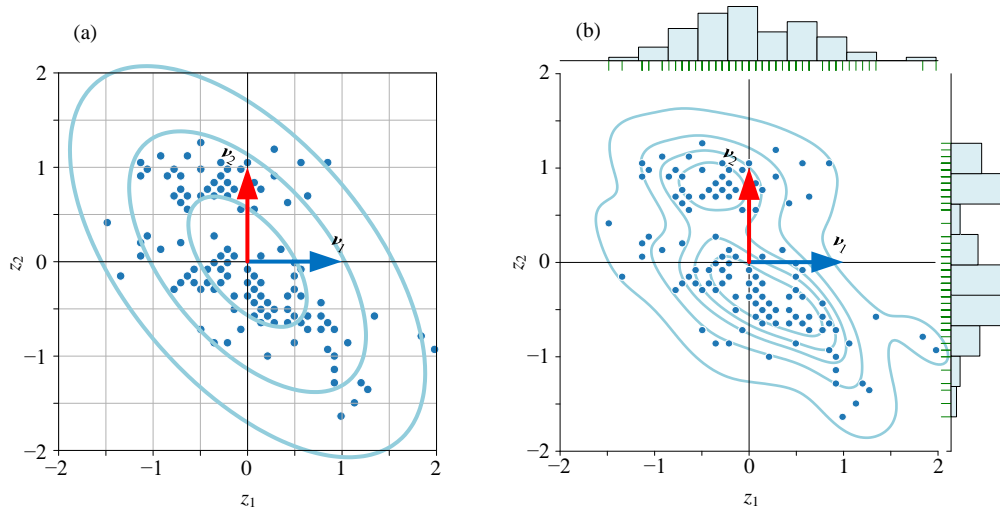


图 24. 数据顺时针旋转 45 度

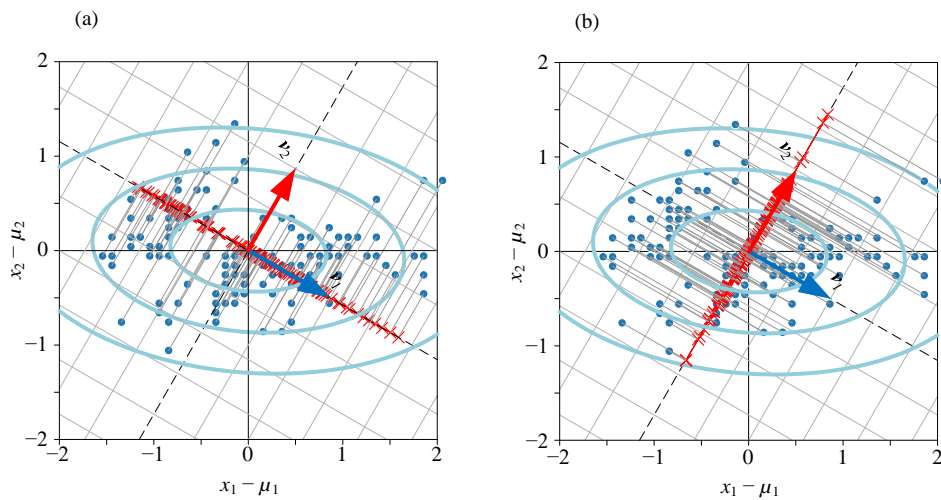


图 25. 正交系，逆时针 30 度

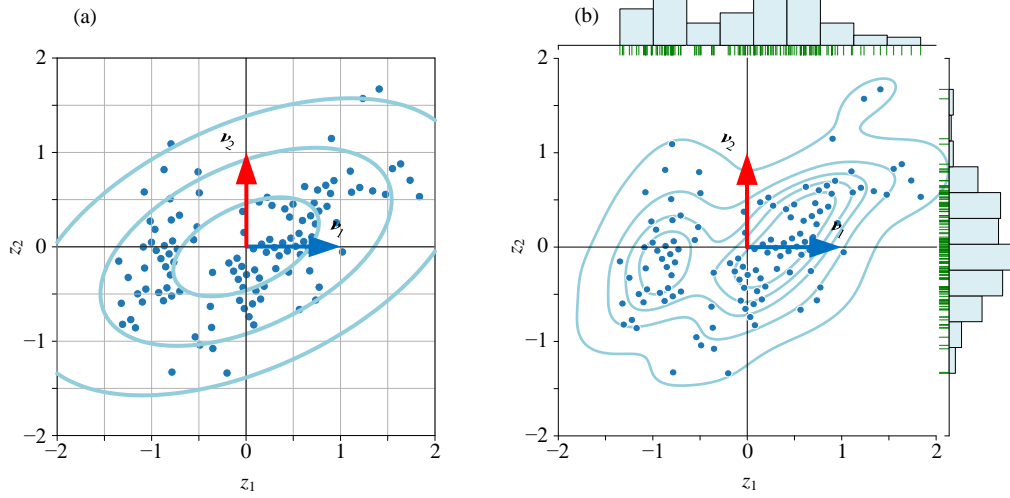


图 26. 数据顺时针旋转-30 度

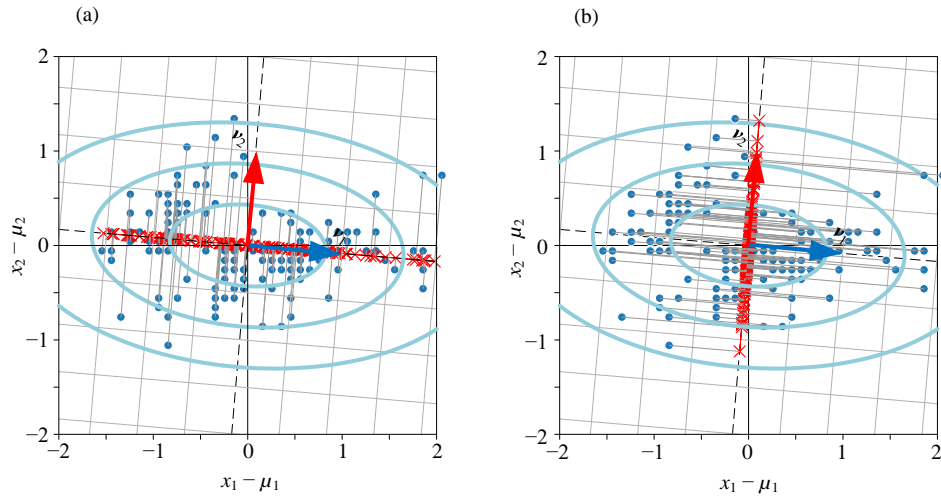


图 27. 正交系，顺时针-4.85 度

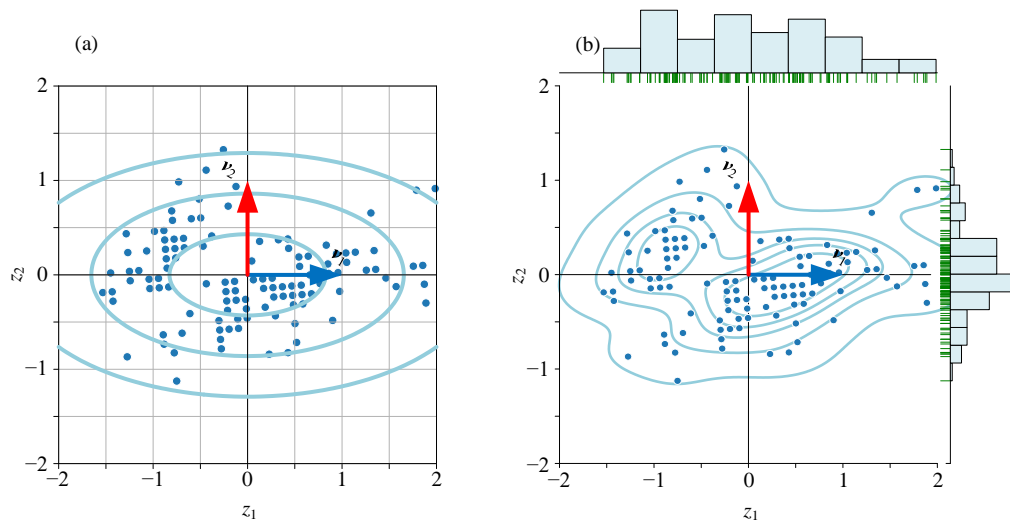


图 28. 数据逆时针旋转-4.85 度